

# 1-chaos

November 14, 2020

Lectura recomendada: [Best Practices for Scientific Computing](#)

## 1 Caos: Primera parte

### 1.1 Introducción

- Edward Lorenz la definió como:

**Caos** Cuando el presente determina el futuro, pero el presente aproximado no determina aproximadamente el futuro.

- La **teoría del caos** estudia el comportamiento de los sistemas dinámicos que son muy sensibles a las condiciones iniciales (El famoso *efecto mariposa* según [Jurassic Park](#)). - Aunque no es lo único, ve más adelante.
- Este hecho hace que la predicción a largo plazo sea imposible.
- Entonces la afirmación **determinismo**  $\rightarrow$  **predictibilidad** es falsa.

Chaos was the law of nature; Order was the dream of man – Henry Adams

- Para saber **muchísimo más** recomiendo: [Chaos Book](#)

Durante siglos en física se estuvo trabajando con sistemas como el [oscilador armónico](#) y el problema de dos cuerpos con fuerza central (también conocido como [problema de Kepler](#)) los cuales se consideraban como paradigmáticos para resolver problemas. La explosión del caos en el siglo XX nos señalaba que esos problemas y métodos no eran la norma, si no al contrario: eran casos especiales.

A lo largo del curso (sobre todo en la última parte) podría quedar el sabor de boca de que las herramientas analíticas son un fraude y que hemos sido engañados durante toda nuestra educación y que el único camino son las simulaciones y la estadística.

Pero eso no es cierto: Existen teorías que tienen el mismo poder predictivo, y el estudio del caso general sigue abriendo el camino para la comprensión científica del mundo.

Lo que si es cierto, es que, partiendo de la definición de que un **sistema determinístico** es aquel que su estado futuro está *completamente* determinado por sus condiciones actuales (en contraste con un sistema estocástico en el cual el futuro está determinado sólo parcialmente) ya no implica **predictibilidad**.

### 1.2 Sensitividad a condiciones iniciales

Una de las características que puede indicar **caos** es la sensibilidad a condiciones iniciales, la cual se puede expresar matemáticamente como:

$$|\delta \mathbf{x}(t)| = e^{\lambda t} |\delta \mathbf{x}(0)|$$

a  $\lambda$  se le conoce como *exponente de Lyapunov*. Si este exponente positivo indica que con el paso del tiempo la diferencia  $\delta$  crece exponencialmente.

**NOTA** La sensibilidad es una idea muy importante pero no determina completamente si el sistema es caótico o no, para ello se necesita otra característica: *mezcla topológica* (topological mixing), la cual veremos más adelante, pero se puede entender como que las trayectorias del sistema, luego de diverger se vuelven a aproximar un número infinito de veces.

### 1.2.1 Mapeos

A los sistemas dinámicos discretos, en una dimensión se les conoce como **mapas**, ya que son funciones

$$f : \mathbb{R} \rightarrow \mathbb{R}$$

y los cuales producen la *secuencia* de puntos:

$$\{x, f(x), f^2(x), f^3(x), \dots\}$$

la cual se conoce como *órbita* de  $x$  bajo  $f$ .

Los sistemas dinámicos discretos, se pueden pensar como ecuaciones de diferencias de primer orden

$$y = x_{n+1} = f(x_n)$$

y regularmente

$$y = f(x) = f(x, a)$$

existe un parámetro  $a$  que puede influir muchísimo en el comportamiento del sistema.

### 1.2.2 Comportamientos

Pueden pasar lo siguiente:

- Si  $f(x) = x$  hemos alcanzado un *punto fijo*.
- Si  $f^n(x) = x$ , pero  $f^k(x) \neq x$  para  $k \leq n$ , se dice que la órbita tiene *periodo* de orden  $n$ .

### 1.2.3 Mapeo logístico

$$x_{n+1} = rx_n(1 - x_n)$$

Donde, para fines de esta clase,  $r$  está contenido en

$$0 \leq r \leq 4$$

la razón de esto, es que el cuadro unitario mapea al cuadro unitario, i.e.

$$0 \leq x \leq 1 \rightarrow 0 \leq f(x) \leq 1$$

**Ejercicio** ¿Por qué?

**Ejercicio** Define la función `logistic_map` que recibe como parámetros  $x$  y  $r$  regresa  $rx(1-x)$ .

```
[1]: def logistic_map(x,r):  
      return r*x*(1-x)
```

Los *puntos fijos* del mapeo logístico son:

$$x = f(x)$$

$$x = rx(1-x)$$

$$1 = r(1-x)$$

$$x = 1 - \frac{1}{r}$$

El punto fijo se dice *estable* si  $|f(x) - x_0| < |x - x_0|$  e *inestable* si la desigualdad se invierte.

**Ejercicio** Calcule el punto fijo para  $r = 2$  usando SymPy

```
[2]: from sympy import *  
x = Symbol("x")  
r = Symbol("r")  
fijo = Eq(x, 1-1/r)  
fijo.rhs.subs(r,2)
```

```
[2]: 1  
      2
```

**Teorema:**

Sea  $f(x_0) = x_0$ ., entonces,

Si  $f'(x)$  es continua y  $|f'(x_0)| < 1$  entonces  $x_0$  es estable.

Si  $f'(x)$  es continua y  $|f'(x_0)| > 1$  entonces  $x_0$  es inestable.

**Ejercicio** ¿Cuáles son las condiciones de estabilidad para el parámetro  $r$ ? Los valores de  $r$  para cuales cambia de estable a inestable y viceversa, se llaman *puntos de bifurcación*.

```
[3]: Eq(Derivative(r*x*(1-x),x).doit().subs(x,fijo.rhs),1).simplify()
```

```
[3]: r = 1
```

```
[4]: Eq(Derivative(r*x*(1-x),x).doit().subs(x,fijo.rhs),-1).simplify()
```

```
[4]: r = 3
```

```
[5]: simplify(Eq(abs(diff(r*x*(1-x), x)).subs(x, 1 - 1/r),1))
```

```
[5]: |r - 2| = 1
```

Ejercicio Programa un control para cambiar  $r$  entre 0 y 4 (con un slider) y otro para definir  $x_0$ . Grafica `logistic_map` respecto al número de iteraciones  $N$ . ¿Qué observas? ¿Puedes ver algún *periodo*? ¿Está cerca de los puntos fijos?

```
[12]: from ipywidgets import interact, fixed
import matplotlib.pyplot as plt
def logistic_map_recursivo(x, r, n=20):
    if n == 1:
        calculo = logistic_map(x,r)
    else:
        calculo = logistic_map(logistic_map_recursivo(x, r, n-1), r)
    return calculo
```

```
[13]: logistic_map_recursivo(.5,2,20)
```

```
[13]: 0.5
```


```
[14]: interact(logistic_map_recursivo,r=(0,4, .1), x=(0,1,.1))
```

```
interactive(children=(FloatSlider(value=0.0, description='x', max=1.0), FloatSlider(value=2.0,
```

```
[14]: <function __main__.logistic_map_recursivo(x, r, n=20)>
```

```
[15]: def log_plot(x, r, n = 20):
    y = []
    for i in range(n):
        y.append(logistic_map_recursivo(x, r, i+1))
    plt.figure(figsize = (8,6), dpi = 80)
    plt.plot(range(n),y)

log_plot(.5, 2)
```




```
[16]: interact(log_plot,x=(0,1,.1), r=(0,4,.1))
```

```
interactive(children=(FloatSlider(value=0.0, description='x', max=1.0), FloatSlider(value=2.0,
```


```
[16]: <function __main__.log_plot(x, r, n=20)>
```

Ejercicio ¿Qué sucede para (a)  $x_0 = 0.35$  en  $r = 2.8$  y (b) para  $x_0 = 0.35$  en  $r = 3.1$ .  
¿Porqué escogí estos valores?

```
[17]: log_plot(.35,2.8)
```



```
[18]: log_plot(.35,3.1)
```



**Ejercicio** Define una función `iterar` que reciba una función  $g$ , un punto inicial  $x_0$ , un entero  $N$  y el parámetro  $r$  regrese  $g(g(\dots(g(x_0, r), r)\dots))$ . En otras palabras que itere  $g$ ,  $N$  veces a partir del punto  $x_0$ .

```
[19]: def iterar(g, x, n, r):
        if n == 1:
            calculo = g(x, r)
        else:
            calculo = g(iterar(g, x, n-1, r), r)
        return calculo
```

**Ejercicio** Define una función `iterarLista` que reciba una función  $g$ , un punto inicial  $x_0$ , un entero  $N$  y el parámetro  $r$  regrese la lista  $[x_0, g(x), g(g(x)), \dots, g(g(\dots(g(x))\dots))]$  En otras palabras que itere  $g$ ,  $N-1$  veces a partir del punto  $x_0$  y devuelva la órbita completa empezando desde  $x_0$ .

```
[22]: def iterarLista(g, x, n, r):
        y = [x]
        for i in range(n):
            y.append(iterar(g, x, i+1, r))
        print(y)
        return y
```

Ejercicio Usa las funciones recién definidas para calcular iteraciones para  $r = \{0.8, 1.2, 2.8, 3.2\}$ ,

```
[23]: =[0.8,1.2,2.8,3.2]
      for i in r:
          iterarLista(logistic_map, .1, 20, i)
```

[0.1, 0.072000000000000002, 0.0534528000000000016, 0.04047647853772801, 0.031070506578330284, 0.024084104159436976, 0.018803248069019493, 0.014759748744859528, 0.011633518849478518, 0.009198544070925876, 0.007291144686320888, 0.005790387116387219, 0.004605486826743676, 0.0036674210542658936, 0.002923176861661297, 0.002331705518957396, 0.0018610149346642076, 0.0014860412464617315, 0.0011870663423004368, 0.0009485257726395314, 0.000758100857198536]

[0.1, 0.108, 0.11560319999999999, 0.12268692017971199, 0.12916180775583477, 0.13497484220769546, 0.14010796101444378, 0.14457326432978265, 0.14840620268497612, 0.15165816202752228, 0.1543895567015473, 0.15666410577965642, 0.15854455648790045, 0.16008981611514647, 0.16135328026963808, 0.16238207905903887, 0.16321696735140348, 0.16389262670401725, 0.16443820033928988, 0.16487793433015852, 0.16523184132141414]

[0.1, 0.252, 0.52778880000000001, 0.697837791264768, 0.5904085833729387, 0.6771136065469955, 0.612166157052565, 0.664772508993766, 0.6239800567837179, 0.656961047455737, 0.631017042828474, 0.651936696567749, 0.6353626726610233, 0.648695451180181, 0.6380910558353027, 0.6466064088352157, 0.6398183704876365, 0.6452623051677097, 0.6409168155526169, 0.6443988630646272, 0.6416171113678004]

[0.1, 0.28800000000000001, 0.65617920000000002, 0.7219457839595519, 0.6423682207442558, 0.7351401271107676, 0.6230691859914625, 0.7515327214700762, 0.5975401280955426, 0.7695549549155365, 0.567488404097546, 0.7854250089995723, 0.5393042055603009, 0.7950565741608756, 0.5214131777422327, 0.7985327226207346, 0.5148102832788849, 0.7992980976294374, 0.5133460760172793, 0.7994300232158112, 0.513093315830332]

### 1.3 Diagrama de CobWeb

Ejercicio Dibuja en una gráfica logistic\_map, como ejes usa  $N_{n+1}$  y  $N_n$ , además agrega la línea  $y = x$  en la misma gráfica. ¿Qué observas para los distintos valores de  $r$ ? Graficala junto a la gráfica anterior.

```
[56]: def logistic_map(x,r):
      return r*x*(1-x)
```

```
[57]: from ipywidgets import interact, fixed
      import matplotlib.pyplot as plt
      import numpy as np
```

```
[119]: def CobWeb (g,x, r, n=20):
      X = [x, x]
```




```

Y = [x]
for i in range(1,n,2):
    aux = g(X[i], r)
    Y.append(aux)
    X.append(aux)
    Y.append(aux)
    X.append(aux)
X.pop()
#Graficamos la funcion inicial y la identidad
plt.figure(figsize=(10, 8), dpi=80)
ejeX = np.linspace(0, 1, 1000)
funcion = []
for i in ejeX:
    funcion.append(g(i,r))
plt.plot(ejeX, ejeX)
plt.plot(ejeX, funcion)
#Graficamos los puntos
plt.plot(X, Y, c='r', alpha=0.7)

```

Ejercicio Agrega los segmentos de línea  $(x_0, x_0), (x_0, f(x_0)), (f(x_0), f(x_0)), (f(x_0), f(f(x_0))), \dots$

[120]: `CobWeb(logistic_map, x=.5, r=3, n=1000)`



```
[123]: interact(CobWeb ,g=fixed(logistic_map),  x=(.0001,1,.1), r=(0,4,.1),
↪n=fixed(500))
```

```
interactive(children=(FloatSlider(value=0.4001, description='x', max=1.0, min=0.0001), FloatSlider(value=4.0, description='r', max=10.0, min=0.0),
```

```
[123]: <function __main__.CobWeb(g, x, r, n=20)>
```

```
[66]: A
```

```
[66]: [0.5,
0.5,
0.025,
0.025,
0.0024375000000000004,
0.0024375000000000004,
0.00024315585937500003,
0.00024315585937500003,
2.4309673460305166e-05,
2.4309673460305166e-05,
```

```

2.430908250008142e-06,
2.430908250008142e-06,
2.430902340693222e-07,
2.430902340693222e-07,
2.4309017497646033e-08,
2.4309017497646033e-08,
2.4309016906717706e-09,
2.4309016906717706e-09,
2.4309016847624875e-10,
2.4309016847624875e-10,
2.4309016841715593e-11]

```

[67]: B

```

[67]: [0.5,
0.025,
0.025,
0.0024375000000000004,
0.0024375000000000004,
0.00024315585937500003,
0.00024315585937500003,
2.4309673460305166e-05,
2.4309673460305166e-05,
2.430908250008142e-06,
2.430908250008142e-06,
2.430902340693222e-07,
2.430902340693222e-07,
2.4309017497646033e-08,
2.4309017497646033e-08,
2.4309016906717706e-09,
2.4309016906717706e-09,
2.4309016847624875e-10,
2.4309016847624875e-10,
2.4309016841715593e-11,
2.4309016841715593e-11]

```

## 1.4 Diagrama de Bifurcación

Ejercicio ¿Qué hace el siguiente código? Modificalo para que use nuestras funciones.

```

[ ]: import math
from PIL import Image
imgx = 1000
imgy = 500
image = Image.new("RGB", (imgx, imgy))

```

```

xa = 1
xb = 4
maxit = 5000

for i in range(imgx):
    r = xa + (xb - xa) * float(i) / (imgx - 1)
    x = 0.5
    for j in range(maxit):
        x = r * x * (1 - x)
        if j > maxit / 2:
            image.putpixel((i, int(x * imgy)), (255, 255, 255))

image.save("bifurcacion.png", "PNG")

```

#### 1.4.1 Pasos para producir el diagrama de bifurcación

1. Escoje un valor inicial para  $r$
2. Escoje un valor al azar para  $x$  en  $[0,1]$
3. Calcula la órbita de  $x$  bajo el  $g$  (en el caso anterior el mapeo logístico)
4. Ignora las primeras  $n$  iteraciones y dibuja el valor de  $x$  para la iteración  $n+1$
5. Incrementa  $r$  y repite hasta  $r$  final.

Ejercicio Repite todo lo anterior para el mapeo

$$f(x, \mu) = 1 - \mu x^2$$

¿Qué diferencia observas? ¿Cuáles son sus puntos fijos? ¿Cuáles son los valores interesantes?